Sistema de Recomendação de Perfumes Nacionais

Hibridização de TF-IDF e SVD para Resolução do Cold-Start

Carlos Victor Albuquerque Oliveira - 232009558
Lucas Sena de Almeida - 190112310

Universidade de Brasília
Departamento de Ciência da Computação
Turma 01, 2026/1
Prof. Díbio

Resumo

Este projeto implementa um sistema híbrido de recomendação que combina TF-IDF (filtragem por conteúdo) e SVD (filtragem colaborativa) para resolver o problema de cold-start em uma loja virtual de perfumes nacionais. A abordagem híbrida 70% TF-IDF + 30% SVD oferece recomendações relevantes e personalizadas mesmo para novos usuários sem histórico de avaliações. O sistema foi validado em uma matriz de 500 usuários × 50 perfumes com 23,6% de densidade, demonstrando efetividade na combinação de explicabilidade com descoberta colaborativa.

1 Introdução

Sistemas de recomendação enfrentam o desafio fundamental do **cold-start**: recomendações para novos usuários sem histórico de interação. As abordagens tradicionais apresentam limitações inerentes:

- **Filtragem por conteúdo pura:** Recomendações genéricas e óbvias
- **Filtragem colaborativa pura:** Impossível sem dados de usuários similares
- **Hibridização:** Combina força de ambas

Neste projeto, desenvolvemos um sistema híbrido para uma loja de perfumes nacionais. A motivação é prática: personalizar recomendações mantendo tanto a explicitabilidade ("você selecionou floral") quanto a descoberta colaborativa ("usuários como você também adoram").

2 Definição do Problema e Dados

2.1 Catálogo de Produtos

O projeto trabalha com um catálogo de **50 perfumes nacionais** de 7 marcas (O Boticário, Natura, Eudora, Avon, Mahogany, Granado, Phebo). Cada perfume possui três características principais:

1. **Família olfativa** (23 tipos): floral, amadeirado, cítrico, oriental, gourmand, aquático, aromático, etc.

2. **Ocasião de uso**: categorias diurno/noturno, formal/casual, verão/inverno (ex: "diurno casual")

3. **Gênero**: masculino ou feminino

Adicionalmente: preço (R$ 50,00 a R$ 350,00), notas olfativas (pirâmide 5-7 componentes), e marca.

2.2 Matriz de Utilidade

A matriz de utilidade foi construída sinteticamente com características realistas:

- **Dimensões:** 500 usuários $\times$ 50 produtos = 25.000 células potenciais
- **Avaliações:** 5.905 registradas (23,6% de densidade)
- **Escala:** 1-5 (inteiros), distribuição realista por persona de usuário
- **Densidade:** Adequada para SVD (recomenda-se $> 10\%$)

A geração de dados é reproduzível e determinística (seed=42): qualquer execução posterior regenera a mesma matriz de utilidade, garantindo validação consistente e comparabilidade dos resultados. Os dados foram gerados com auxílio de IA (Claude, Anthropic) pelo script `gerar_dados.py`, que simula personas de usuários com preferências de família olfativa, ocasião e gênero, atribuindo notas com base no grau de compatibilidade entre o perfil da persona e as características do perfume. Todo o código-fonte, dados e modelos estão disponíveis e comentados no repositório: `https://github.com/Carlos-Vic/sistema-recomendacao`.

3 Metodologia

3.1 Fase 1: Filtragem por Conteúdo (TF-IDF)

O algoritmo TF-IDF gera candidatos iniciais baseado no perfil declarado do usuário.

3.1.1 Fundamentos Matemáticos

Dado um documento d e termo t, o score TF-IDF é:

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \text{IDF}(t) \tag{1}$$

onde:

$$\text{TF}(t, d) = \log(1 + f_{t,d}) \quad \text{(frequência do termo)} \tag{2}$$

$$\text{IDF}(t) = \log\left(\frac{N}{n_t}\right) \quad \text{(peso inverso global)} \tag{3}$$

com $N = 50$ (total de perfumes) e n_t = número de perfumes contendo termo t.

Intuição: Termos raros aumentam sua relevância discriminativa. Por exemplo, "amadeirado noturno" é mais específico que apenas "amadeirado", oferecendo maior poder de discriminação entre produtos similares.

3.1.2 Fluxo de Vetorização

1. Concatenar características: "floral" + "noturno casual" + "feminino"
2. Tokenizar em scikit-learn (TfidfVectorizer)
3. Gerar matriz TF-IDF 50×D (D = vocab size, pré-calculado)
4. Calcular similaridade por cosseno: $\cos(\vec{u}, \vec{v}) = \frac{\vec{u} \cdot \vec{v}}{|\vec{u}||\vec{v}|}$

Resultado: Score TF-IDF normalizado em [0, 1] para cada perfume. Aplicam-se filtros (gênero, preço), selecionam-se top-20.

3.2 Fase 2: Filtragem Colaborativa (SVD)

O SVD reordena os top-20 candidatos de TF-IDF usando padrões de usuários similares.

3.2.1 Matrix Factorization

A matriz de utilidade $R \in \mathbb{R}^{500 \times 50}$ é decomposta:

$$R = U \Sigma V^T \approx \hat{U} \hat{\Sigma} \hat{V}^T \tag{4}$$

mantendo $k = 15$ fatores singulares. As matrizes resultantes são:

$$U \in \mathbb{R}^{500 \times 15} \quad \text{(preferências latentes por usuário)} \tag{5}$$

$$V^T \in \mathbb{R}^{15 \times 50} \quad \text{(características latentes por perfume)} \tag{6}$$

Multiplicação $U \Sigma V^T$ prediz todas as 25.000 células, inclusive as vazias.

3.2.2 Reordenação Colaborativa

1. Identificar 50 usuários mais similares ao novo usuário (via TF-IDF no perfil)
2. Extrair predições SVD para os top-20 perfumes: $\hat{R}[50 \text{ usuários}, \text{top-20}]$
3. Calcular score médio: $s_j = \frac{1}{50} \sum_{i=1}^{50} \hat{R}_{ij}$
4. Normalizar em [0, 1]: $s_norm_j = \frac{s_j - 1}{4}$ (escala de notas 1-5)

3.3 Hibridização

O score final combina ambas as abordagens:

$$\text{score}_{\text{final}}(j) = 0.7 \times \text{tfidf}(j) + 0.3 \times \text{svd_norm}(j) \tag{7}$$

Justificativa dos pesos: 70% TF-IDF pois com 50 produtos o conteúdo é altamente discriminativo e oferece explicabilidade ao usuário. 30% SVD captura padrões colaborativos sem overfitting dado a densidade de 23,6%.

Threshold de qualidade: Score ≥ 0.50 retorna recomendação. Abaixo disso, ativa fallback.

4 Cascata de Fallback

Quando o modelo não encontra match satisfatório, implementa-se 4 níveis progressivos:

Nível 0 (Match Perfeito) Todas as restrições (família + ocasião + gênero + preço), com validação que família aparece no produto. Mensagem: "Recomendação personalizada".

Nível 1 (Ocasião Restritiva) Remove ocasião (algumas são raras). Score ≥ 0.50. Mensagem: "Poucas opções para essa ocasião".

Nível 2 (Gênero Cruzado) Remove gênero (famílias desbalanceadas por gênero). Score ≥ 0.50. Mensagem: "Seu perfil é raro. Mostrando similares".

Nível 3 (Top-5 Populares) Sem filtros, retorna mais vendidos por gênero. Mensagem: "Sem match ideal. Mostrando os perfumes mais populares."

5 Resultados e Validação

5.1 Métricas do SVD

O modelo SVD foi avaliado com divisão treino/teste (80%/20%), obtendo:

- **RMSE:** 0,6092 — erro médio de menos de 1 estrela na escala 1–5
- **Variância explicada:** 51,8% com $k = 15$ fatores latentes

5.2 Distribuição do Fallback

O sistema foi testado com 100 cenários aleatórios:

- Nível 0: 55% (match perfeito muito comum)
- Nível 1: 25% (ocasião é realmente restritiva)
- Nível 2: 15% (gênero desbalanceado para algumas famílias)
- Nível 3: 5% (combinações impossíveis raras)

6 Como Usar

A aplicação foi desenvolvida em **Gradio** e é executada no Jupyter Notebook. Para iniciar:

1. **Instalar Dependências:** Execute a célula de instalação no início do notebook: `%pip install pandas scikit-learn scipy seaborn matplotlib gradio joblib`
2. **Inicializar o Backend:** Execute **todas as células do Tópico 5** ("app.py") do notebook. Isso carrega os modelos (TF-IDF, SVD) e inicia a interface web.
3. **Cadastro/Login:** Insira e-mail, senha e nome. Defina suas preferências: gênero, famílias olfativas preferidas, ocasião de uso e orçamento máximo.
4. **Minha Vitrine:** Clique para visualizar top-5 perfumes recomendados. Cada card exibe: imagem, marca, família olfativa, notas, avaliação (), preço e percentual de match.

5. **Pedido:** Marque os perfumes desejados e clique em "Confirmar Pedido".

6. **Feedback:** Avalie os perfumes com notas (1-5) e comentários opcionais. Dados salvos em `feedback.csv`.

Mensagens Visuais: O sistema comunica transparentemente o nível de fallback acionado (Nível 0 = match perfeito, Níveis 1-3 = relaxamento progressivo de restrições).

7 Conclusão

O projeto implementa com sucesso um sistema híbrido que combina TF-IDF (explicabilidade + cold-start) e SVD (colaboração + serendipidade) na proporção 70/30. A cascata de fallback com 4 níveis garante cobertura (sempre retorna algo) sem sacrificar relevância (threshold 0.50).

As contribuições principais são: hibridização efetiva que resolve cold-start mantendo interpretabilidade, validação explícita de restrições reduzindo falsos positivos, e cascata robusta de fallback com relaxamento inteligente. A abordagem escala bem para catálogos pequenos-médios e pode ser estendida com retreinamento periódico do SVD conforme novos ratings acumulem.

Referências

- Ricci, F., Rokach, L., & Shapira, B. (Eds.). (2015). *Recommender Systems Handbook*. Springer.

- Koren, Y., Bell, R., & Volinsky, C. (2009). Matrix factorization techniques for recommender systems. *IEEE Computer*, 42(8), 30–37.

- Lops, P., De Gemmis, M., & Semeraro, G. (2011). Content-based recommender systems: State of the art and trends. In *Recommender systems handbook* (pp. 73–105). Springer.